SPÉCIFICATIONS TECHNIQUES & CAHIER DES CHARGES

CineVoice AI — Automation Audio vers Série Vidéo

Version: 1.0 (Final) **Statut:** Validé pour Développement **Date:** Octobre 2026

> **Vision Produit (Zero-Touch Automation)**
> L'utilisateur transmet uniquement un fichier audio (discours brut jusqu'à 10 minutes). Le système analyse le contenu, découpe l'argumentaire en épisodes autonomes (max 1 minute chacun), génère les visuels enrichis, effectue le montage adaptatif et produit une série de vidéos clé en main prête à être diffusée sur TikTok, Instagram Reels et YouTube Shorts.

1. OBJECTIFS & PÉRIMÈTRE FONCTIONNEL

Le système agit comme un **Directeur Artistique et Monteur Vidéo IA Autonome**. Il résout la complexité de création de contenu court à partir de sessions d'enregistrement audio non structurées.

- **Ingestion Simplifiée:** Entrée audio unique via API (support format .mp3, .wav, .m4a).
- **Traitement Autonome:** Transcription, découpage thématique, structuration en arc narratif, génération d'images/vidéos contextuelles et montage.
- **Format de Sortie:** Collection de vidéos au format vertical (9:16 - 1080x1920) dynamiques, sous-titrées et synchronisées, prêtes pour publication sociale.

2. ARCHITECTURE GLOBALE DU SYSTÈME

L'architecture repose sur un modèle asynchrone drivé par événements pour absorber la charge de rendu lourd.

ÉTAPE	MODULE / SERVICE	TECHNOLOGIE / API	RÔLE SPÉCIFIQUE
1. Ingestion	API Gateway & Storage	FastAPI / S3 Storage	Réception de l'audio, validation et stockage sécurisé.
2. Transcription	STT Engine	OpenAI Whisper / Deepgram	Transcription textuelle précise avec horodatage mot à mot.
3. Analyse & Script	LLM Director Orchestrator	Claude 3.5 Sonnet / GPT-4o	Extraction des accroches, découpage en épisodes et shot list.
4. Génération Visuelle	Asset Generation Pipeline	Flux.1 / Midjourney / Kling AI	Création des images clés et animation dynamique (Img2Vid).
5. Montage & Subtitles	Rendering Engine	FFmpeg / Python MoviePy	Stitching des plans, mixage audio et incrustation sous-titres.
6. Distribution	Delivery Layer	AWS CloudFront CDN	Mise à disposition des liens de téléchargement sécurisés.

3. PIPELINE DÉTAILLÉ PAS-À-PAS

Étape 3.1 — Transcription & Alignment Temporel

L'audio brut est traité par le moteur STT pour produire un dictionnaire structuré contenant la transcription textuelle et les *word-level timestamps* nécessaires à la synchronisation exacte des sous-titres et des transitions vidéo.

Étape 3.2 — Découpage Narratif (LLM Orchestrator)

Un prompt structuré demande au LLM d'analyser la transcription pour isoler 1 à N idées fortes autonomes (les épisodes). Pour chaque épisode (durée < 60s), le LLM fournit un JSON strict spécifiant :

- L'extrait audio exact à couper (timestamps début/fin).
- La répartition en scènes (3 à 6 secondes par plan).
- Les prompts visuels pour chaque scène (adaptés au style demandé).
- Les mots-clés à mettre en avant dans le sous-titrage dynamique.

4. SPÉCIFICATIONS DE L'API REST

Soumission de Job (POST /api/v1/series/generate)

Endpoint asynchrone acceptant le fichier audio et les paramètres de personnalisation.

```
POST /api/v1/series/generate HTTP/1.1
Content-Type: multipart/form-data

audio_file: [Fichier binaire]
visual_style: "cinematic_photorealistic"  // options: anime, 3d_render, minimal_flat
aspect_ratio: "9:16"                     // options: 9:16, 16:9
max_episode_duration: 60                 // secondes
webhook_url: "https://client.com/api/callback"
```

Réponse Job Créé (HTTP 202 Accepted)

```
{
  "job_id": "job_cv_982347101",
  "status": "queued",
  "estimated_processing_time_sec": 180,
  "created_at": "2026-10-30T14:00:00Z"
}
```

Représentation Schema du Résultat (Polling / Webhook Payload)

```
{
  "job_id": "job_cv_982347101",
  "status": "completed",
  "episodes_count": 3,
  "series": [
    {
      "episode_index": 1,
      "title": "Partie 1: L'Origine du Concept",
      "duration_sec": 54.2,
      "video_url": "https://cdn.cinevoice.ai/outputs/job_cv_982347101_ep1.mp4",
      "thumbnail_url": "https://cdn.cinevoice.ai/outputs/thumb_ep1.jpg"
    },
    {
      "episode_index": 2,
      "title": "Partie 2: L'Exécution Technique",
      "duration_sec": 58.0,
      "video_url": "https://cdn.cinevoice.ai/outputs/job_cv_982347101_ep2.mp4",
      "thumbnail_url": "https://cdn.cinevoice.ai/outputs/thumb_ep2.jpg"
    }
  ]
}
```

5. MOTEUR DE RENDU VIDÉO & AUTO-EDITING

Le module de montage automatisé suit des règles de composition strictes :

- **Rythme & Cut:** Changement de plan toutes les 3.5 à 5 secondes pour garantir un taux de rétention élevé.
- **Sous-Titrage Dynamique:** Génération de fichiers `.ass` avec animation mot à mot (Karaoke style, surbrillance jaune/verte, police heavy bold).
- **Coherence Visuelle:** Injection d'un "Style Seed" et d'un prompt maître dans le générateur d'images pour maintenir la charte graphique sur toute la série.

6. MATRICE DE RISQUES & SOLUTIONS TECHNIQUES

RISQUE IDENTIFIÉ	IMPACT	SOLUTION & MITIGATION
Incohérence des visuels entre les scènes	Élevé	Passage d'un identifiant de style unique + injection du même seed et d'une description de personnage constante dans le prompt.
Échec de formatage JSON par le LLM	Moyen	Utilisation de frameworks de validation stricts (ex: Instructor / Pydantic) avec reprise sur erreur automatique.
Temps de rendu trop long (> 5 min)	Moyen	Génération parallèle des images/vidéos de chaque scène via des workers Celery distribués.

7. PROCHAINES ÉTAPES DE DÉVELOPPEMENT

1. Configuration du pipeline de transcription et du parser JSON LLM.
2. Intégration du moteur de génération visuelle (API Flux/Fal.ai).
3. Écriture des scripts d'assemblage FFmpeg et d'incrustation des sous-titres.
4. Déploiement du serveur API FastAPI avec file d'attente Redis / Celery.